Rapport EcoLab

Documentation technique complète

De la modélisation thématique (BERTopic)

à la cartographie interactive
des scores de préservation du territoire du SCoT

Auteur : ALVES Enrique, PINA Ruben, FAGE Annaelle, MAITRET Charles, YOUNES Rayane

Version : 2.0

Date : Mars 2026

Territoire : SCoT Drôme Ardèche (D007, D026, D084)

Corpus : ≈50 000 articles de presse environnementale

Table des matières

1 BERTopic **5**

1.1 Introduction et vue d'ensemble . . . 5

1.1.1 Objectif du projet . . . 5

1.1.2 Vue d'ensemble de la pipeline . . . 6

1.1.3 Volumes de données . . . 7

1.2 Modélisation thématique — BERTopic . . . 7

1.2.1 Objectif et principe . . . 7

1.2.2 Entraînement (`bertopic_train_save.py`) . . . 7

1.2.3 Séparation pertinent / non-pertinent . . . 9

1.2.4 Visualisation (`bertopic_code_heatmap_visu.py`) . . . 9

1.3 Étape 01 — Scoring Ollama des articles . . . 9

1.3.1 Objectif . . . 9

1.3.2 Grille de scoring . . . 10

1.3.3 Architecture d'appel . . . 10

1.3.4 Logique de reprise (checkpoint) . . . 10

1.3.5 Sorties . . . 10

1.4 Étape 02 — Visualisation des topics . . . 11

1.4.1 Graphiques produits . . . 11

1.5 Étape 03 — Score géospatial COSIA . . . 11

1.5.1 Objectif . . . 11

1.5.2 Construction du score par classe . . . 11

1.5.3 Architecture de traitement parallèle . . . 11

1.5.4 Filtre géographique . . . 12

1.5.5 Sorties . . . 12

1.6 Étape 04 — Enrichissement BD TOPO . . . 12

1.6.1 Objectif . . . 12

1.6.2 Les 14 catégories BD TOPO . . . 13

1.6.3 Score BD TOPO et score final . . . 13

1.6.4 Optimisations . . . 13

1.6.5 Sorties . . . 13

1.7 Étape 05 — Export QGIS . . . 14

1.7.1 Quintiles et couleurs . . . 14

1.7.2 Fichier QML . . . 14

1.7.3 Grille de tuiles 1km × 1km . . . 14

1.7.4 Sorties . . . 14

1.8 Étape 06a — Articles par parcelle . . . 14

1.8.1 Objectif . . . 14

1.8.2 Workflow en 2 temps . . . 15
1.8.3 Articles synthétiques . . . 15
1.8.4 Cache d'embeddings . . . 15
1.8.5 Résumé COSIA par Ollama . . . 15
1.8.6 Sorties . . . 15
1.9 Étape 06b — Résumés BD TOPO . . . 15
1.9.1 Objectif . . . 15
1.9.2 Clé de combinaison . . . 16
1.9.3 Seuil et filtrage . . . 16
1.9.4 Sorties . . . 16
1.10 Étape 06c — Injection des résumés dans le GPKG . . . 16
1.10.1 Objectif . . . 16
1.10.2 Optimisations SQLite . . . 16
1.10.3 Logique de mise à jour . . . 16
1.11 Application web interactive . . . 17
1.11.1 Architecture technique . . . 17
1.11.2 Flask — Routes API . . . 17
1.11.3 Filtre et chargement . . . 17
1.11.4 Système de cache des bbox . . . 18
1.11.5 Sidebar Streamlit — Filtres . . . 18
1.11.6 Panel de détail parcelle . . . 18
1.11.7 Carte Leaflet . . . 19
1.11.8 Performances . . . 19
1.12 Index SQLite et optimisations . . . 19
1.12.1 Index créés . . . 19
1.13 Configuration centrale . . . 20
1.14 Lancement de la pipeline . . . 21
1.14.1 Prérequis . . . 21
1.14.2 Ordre d'exécution . . . 21
1.14.3 Lancement de l'application web . . . 21
1.15 Flux de données complet . . . 22
1.16 Résultats et visualisation QGIS . . . 22
1.16.1 Couches disponibles dans le GPKG final . . . 22
1.16.2 Jointure des résumés dans QGIS . . . 22
1.17 Choix techniques et justifications . . . 23
1.18 Glossaire . . . 23

2 Score par ACP **25**
2.1 Contexte et Objectifs . . . 25
2.2 Les 12 Indicateurs . . . 25
2.3 Analyse en Composantes Principales . . . 26
2.3.1 Principe . . . 26
2.3.2 Résultat de l'ACP finale . . . 27
2.4 Construction du Score . . . 28
2.4.1 Orientation des axes . . . 28
2.4.2 Formule du score brut . . . 28
2.4.3 Normalisation 0–100 et rôle du min/max . . . 29

2.5 Validations du Score 30
2.5.1 Test de sensibilité des pondérations 30
2.5.2 Contribution de chaque source 30
2.6 Cartographie et Résultats 30
2.6.1 Distribution du score 30
2.6.2 Carte du score de potentiel écologique 31
2.6.3 Interprétation spatiale 31
2.7 Limites et Perspectives 31
2.7.1 Limites 31

Introduction

L'aménagement durable des territoires nécessite aujourd'hui des outils de diagnostic précis, capables de concilier les dynamiques de développement local et les impératifs de préservation de la biodiversité. C'est dans ce contexte que s'inscrit le projet EcoLab, conçu spécifiquement pour le périmètre du Schéma de Cohérence Territoriale (SCOT) Drôme-Ardèche. Ce rapport technique, achevé en mars 2026, détaille l'intégralité d'une chaîne de traitement innovante visant à évaluer et cartographier les pressions d'artificialisation et la richesse écologique de ce territoire.

Les objectifs de la démarche

La finalité du projet EcoLab est de fournir aux décideurs et aux planificateurs un outil cartographique interactif et méthodologiquement robuste. Nos objectifs principaux sont de :

— Identifier les zones à fort potentiel écologique pour y prioriser les actions de conservation.

— Orienter de manière stratégique les inventaires naturalistes sur le terrain.

— Argumenter de façon chiffrée les zonages de protection dans le cadre de la révision du SCOT et des Plans Locaux d'Urbanisme intercommunaux (PLUi).

— Constituer un socle de données reproductible et opposable pour les futures études d'impact environnemental.

Une approche hybride et multi-échelles

Pour répondre à ces exigences complexes, notre méthodologie s'articule autour de deux axes de modélisation complémentaires :

1. **Une analyse sémantique et spatiale à l'échelle de la parcelle (Chapitre 1) :** Nous avons déployé une pipeline combinant l'Intelligence Artificielle et les Systèmes d'Information Géographique (SIG). En analysant un corpus d'environ 50 000 articles de presse environnementale grâce à la modélisation thématique (BERTopic) et à un modèle de langage (Mistral via Ollama), nous avons extrait un "signal territorial". Croisé à parité (50/50) avec le contexte géographique de la BD TOPO, ce signal permet d'attribuer à chaque polygone d'occupation des sols (COSIA) un score d'artificialisation allant de -2 (protecteur) à +2 (favorable au développement).
2. **Une modélisation statistique globale à l'échelle de l'IRIS (Chapitre 2) :** Pour compléter cette vue granulaire, nous avons construit un score continu de potentiel écologique allant de 0 à 100. Ce score repose sur une Analyse en Composantes Principales (ACP) qui synthétise 12 indicateurs environnementaux et de pression issus de trois bases de données de référence (CarHAB, BD Forêt V2 et COSIA).

Ce document documente en toute transparence nos choix techniques et d'architecture, depuis le traitement initial des données jusqu'à l'export final sous QGIS et le développement de notre application web interactive.

Chapitre 1

BERTopic

1.1 Introduction et vue d'ensemble

1.1.1 Objectif du projet

La pipeline EcoLab vise à produire une **carte de score d'artificialisation** à l'échelle parcellaire sur le territoire du SCoT (Drôme-Ardèche). Pour chaque polygone de la couche COSIA, un score compris entre -2 (très favorable à la nature) et $+2$ (très favorable à l'artificialisation) est calculé à partir de deux sources complémentaires :

1. **Le signal presse** : des articles de presse environnementale sont analysés par un modèle de langage (Ollama / Mistral) et regroupés par thème via BERTopic. Chaque classe d'occupation du sol hérite du score moyen des thèmes qui lui sont associés.
2. **Le contexte géographique** : les couches BD TOPO (parcs naturels, forêts publiques, zones de végétation, cours d'eau, barrages, éoliennes...) enrichissent le score via un croisement spatial.

Le score final est une combinaison pondérée 50/50 des deux sources, et est visualisé via QGIS et une application web Streamlit/Leaflet.

1.1.2 Vue d'ensemble de la pipeline

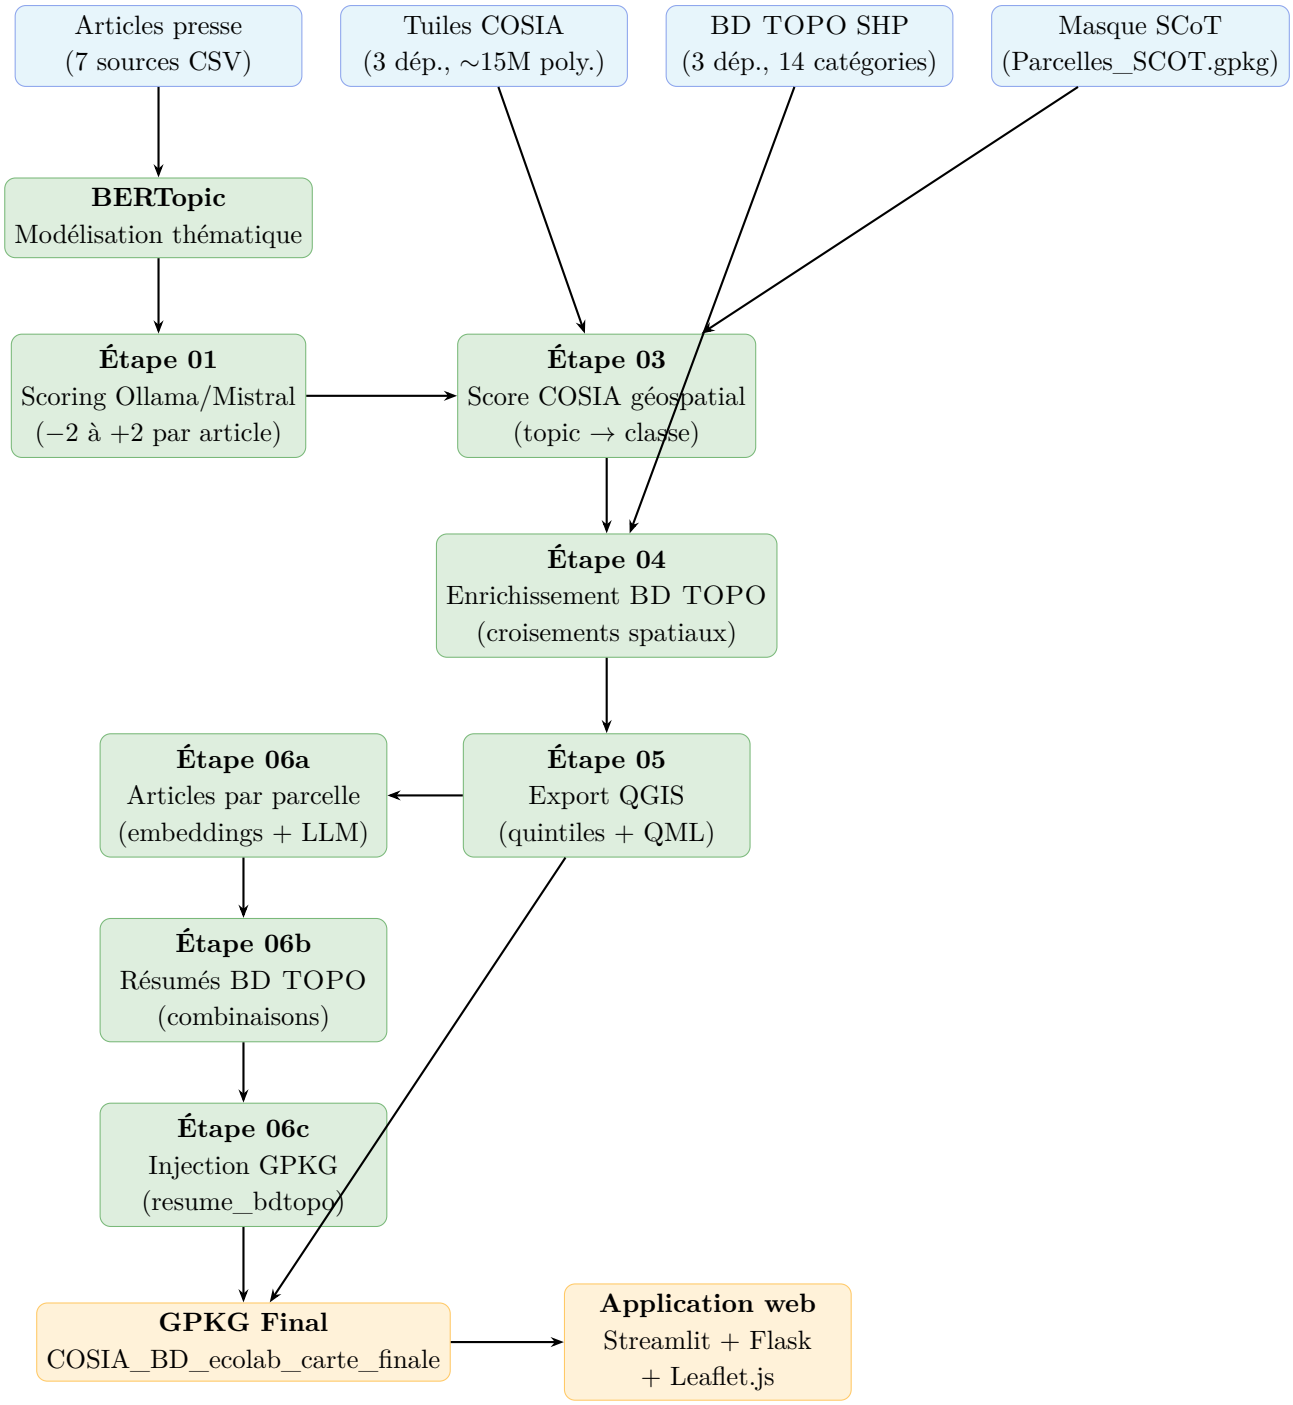

FIGURE 1.1 – Schéma général de la pipeline EcoLab v2

1.1.3 Volumes de données

Composant	Volume	Remarques
Articles de presse	∼50 000	Dédupliqués par URL
Topics BERTopic	125+	Variable selon le run
Classes COSIA	15	Fixes (nomenclature)
Catégories BD TOPO	14	Fixes (nomenclature)
Polygones COSIA (final)	∼15 millions	3 départements
GPKG final	29,7 Go	Index R-Tree + 15 index SQL
Articles synthétiques	29	15 COSIA + 14 BD TOPO
Combos BD TOPO avec résumé	∼160	Après seuil MIN_POLYGONS

Table 1.1 – Volumes de données de la pipeline

1.2 Modélisation thématique — BERTopic

1.2.1 Objectif et principe

BERTopic est un modèle de *topic modeling* neuronal qui exploite des embeddings de phrases (Sentence-BERT) pour regrouper des articles en thèmes cohérents. Il résout le problème clé suivant : **comment distinguer automatiquement les articles pertinents pour l'artificialisation des sols de ceux qui ne le sont pas ?**

Le workflow est :

1. Encoder chaque article en vecteur dense (modèle multilingue)
2. Réduire la dimension avec UMAP
3. Clusteriser avec HDBSCAN
4. Extraire les mots-clés de chaque cluster via TF-IDF de classe (c-TF-IDF)
5. Attribuer un label humain-lisible à chaque topic

1.2.2 Entraînement (`bertopic_train_save.py`)

Sources de données

Source	Fichier CSV	Type
Cerema	`cerema_actualites.csv`	Actualités institutionnelles
Actu-Environnement	`actu_environnement_actualites.csv`	Presse spécialisée
Le Dauphiné	`ledauphine_articles.csv`	Presse régionale
Le Monde	`lemonde_articles.csv`	Presse nationale
Vert.eco	`vert_eco_articles.csv`	Presse écologie

Table 1.2 – Sources d'articles utilisées

Paramètres du modèle

```python
# Modele d'embeddings multilingue
embedding_model = SentenceTransformer(
    "paraphrase-multilingual-MiniLM-L12-v2"
)

# Reduction de dimension
umap_model = UMAP(
    n_components=5,
    metric="cosine",
    random_state=42
)

# Clustering
hdbscan_model = HDBSCAN(
    min_cluster_size=20,
    prediction_data=True
)

# Vectorisation TF-IDF avec stopwords francais
vectorizer = CountVectorizer(
    ngram_range=(1, 2),
    stop_words=FRENCH_STOPWORDS  # ~45 mots
)

# Modele final
topic_model = BERTopic(
    embedding_model=embedding_model,
    umap_model=umap_model,
    hdbscan_model=hdbscan_model,
    vectorizer_model=vectorizer,
    nr_topics=50,
    min_topic_size=20
)
```

Listing 1.1 – Initialisation de BERTopic (bertopic_train_save.py)

Pré-traitement

- Mise en minuscules, normalisation des espaces
- Filtrage : documents < 80 caractères supprimés
- Déduplication par URL

Sorties

- `docs_with_topics.csv` — chaque article avec son topic et sa probabilité
- `topics_info.csv` — métadonnées (topic ID, nom, top mots-clés, n documents)
- `bertopic_model/` — modèle sérialisé (réutilisable)

1.2.3 Séparation pertinent / non-pertinent

Après l'entraînement, les topics sont examinés manuellement et mappés :

— **Topics pertinents (125+)** : associés à au moins une classe COSIA ou catégorie BD TOPO dans `TOPIC_COSIA_MAP` et `TOPIC_BDTOPO_MAP` de `config_v2.py`

— **Topic** -1 : documents hors-thème (outliers HDBSCAN), ignorés

— **Topics non mappés** : thèmes généraux (politique, santé, sport...) sans lien territorial, ignorés dans le scoring

Exemple de mapping topic → classe COSIA

```
TOPIC_COSIA_MAP = {
3: ["Bâtiment", "Zone imperméable"],  # topic 3 = urbanisme
7: ["Feuillu", "Conifère"],        # topic 7 = forêt
12: ["Surface eau"],               # topic 12 = eau
...}
```

1.2.4 Visualisation (`bertopic_code_heatmap_visu.py`)

Plusieurs graphiques sont générés pour explorer et valider le modèle :

1. **Distribution** : histogramme (topic ID vs. nombre de documents)
2. **Heatmap topic × source** : crosstab des counts par source de données
3. **UMAP documents** : nuage de points 2D coloré par topic (outliers inclus)
4. **UMAP topics** : centroïdes des topics avec taille proportionnelle au nombre de documents, labels TF-IDF affichés
5. **Tableau récapitulatif** : export CSV (topic ID, nom, n_docs)

1.3 Étape 01 — Scoring Ollama des articles

Script : `01_topic_notes_ollama_v2.py`

1.3.1 Objectif

Pour chaque article du corpus (après assignation des topics par BERTopic), un score d'artificialisation est attribué par un LLM local (Mistral via Ollama) selon une grille de -2 à $+2$.

1.3.2 Grille de scoring

Score	Signification
−2	Résiste fortement à l'artificialisation (biodiversité, qualité de l'eau, espaces agricoles, zones protégées)
−1	Dominante environnementale légère (mobilité douce, agriculture durable)
0	Pas de lien territorial / neutre
+1	Dominante développement légère (transports, réhabilitation de friches)
+2	Favorise l'artificialisation (construction, infrastructure, immobilier)

Table 1.3 – Grille de scoring Ollama

1.3.3 Architecture d'appel

```python
def ollama_call(prompt: str) -> str:
    """Appel POST a l'API Ollama locale (localhost:11434)."""
    payload = {
        "model": "mistral",
        "prompt": prompt,
        "stream": False
    }
    r = requests.post(OLLAMA_URL, json=payload, timeout=120)
    return r.json()["response"]

def parse_score(raw: str) -> int | None:
    """Extrait un entier entre -2 et +2 de la reponse LLM."""
    matches = re.findall(r"[-+]?\d", raw)
    for m in matches:
        v = int(m)
        if -2 <= v <= 2:
            return v
    return None
```

Listing 1.2 – Appel Ollama avec parsing robuste du score

1.3.4 Logique de reprise (checkpoint)

Toutes les 50 articles, le fichier `docs_scored_v2.csv` est sauvegardé. Au prochain lancement, les articles déjà scorés sont sautés automatiquement — le traitement peut être interrompu et repris.

1.3.5 Sorties

- `docs_scored_v2.csv` — tous les articles avec leur score LLM
- `topic_score_summary_v2.csv` — score moyen/médian par topic (agrégation par `groupby("topic")`)

1.4 Étape 02 — Visualisation des topics

Script : `02_topic_viz_v2.py`

1.4.1 Graphiques produits

1. **Distribution** : barres horizontales, nombre de documents par topic (trié croissant)
2. **Scores** : barres horizontales, score moyen Ollama par topic avec codage couleur par quintile :

Couleur	Hex	Seuil
Rouge foncé	**#d73027**	≤ -0.5 (très protecteur)
Orange	**#fc8d59**	-0.5 à 0 (protecteur)
Gris	**#d9d9d9**	0 (neutre)
Vert clair	**#91cf60**	0 à 0.5 (développement)
Vert foncé	**#1a9641**	≥ 0.5 (très développement)

Table 1.4 – Codage couleur des scores de topic (teintes pastel)

1.5 Étape 03 — Score géospatial COSIA

Script : `03_geospatial_score_cosia_v2.py`

1.5.1 Objectif

Assigner un score d'artificialisation à chaque polygone de la couche COSIA en fonction de sa classe d'occupation du sol, via le mapping `TOPIC_COSIA_MAP`.

1.5.2 Construction du score par classe

Pour chaque classe COSIA :

$$\text{score_classe}(c) = \frac{1}{|T_c|} \sum_{t \in T_c} \text{score_moyen}(t)$$

où T_c est l'ensemble des topics mappés à la classe c.

1.5.3 Architecture de traitement parallèle

```python
# 6 workers I/O en parallele, traitement sequentiel
with ThreadPoolExecutor(max_workers=6) as executor:
    futures = {
        executor.submit(read_and_filter_tile, tile): tile
        for tile in all_tiles
    }
    for future in as_completed(futures):
        gdf = future.result()
        if gdf is not None and len(gdf) > 0:
```

```
            process_gdf(gdf)  # sequentiel pour la memoire
```

Listing 1.3 – Lecture parallèle des tuiles COSIA

1.5.4 Filtre géographique

Plutôt qu'un découpage géométrique coûteux, un simple filtre par *bounding box* (Lambert 93) est appliqué : les polygones dont le centroïde est en dehors du SCoT sont exclus. La bbox du SCoT est :

$$(816\,777,\ 6\,340\,562,\ 914\,455,\ 6\,407\,100)\ \text{[Lambert 93]}$$

1.5.5 Sorties

- `COSIA_SCORE_v2.gpkg` — polygones scorés (~15M lignes)
- `COSIA_SCORE_v2_attrs.csv` — attributs seuls (sans géométrie)

1.6 Étape 04 — Enrichissement BD TOPO

Script : `04_enrich_cosia_bdtopo_v2.py`

1.6.1 Objectif

Enrichir chaque polygone COSIA avec son contexte géographique BD TOPO : 14 colonnes booléennes `bdtopo_*` indiquent si le polygone intersecte une zone protégée, une forêt publique, un cours d'eau, etc.

1.6.2 Les 14 catégories BD TOPO

Catégorie	Colonne	Type de zone
Natura 2000	`bdtopo_NATURA2000`	Protection européenne
Parc naturel régional	`bdtopo_PARC_PNR`	Protection nationale
Réserve naturelle	`bdtopo_RESERVE_NAT`	Protection nationale
Géoparc	`bdtopo_GEOPARC`	Label UNESCO
Forêt publique	`bdtopo_FORET_PUBLIQUE`	ONF
Zone végétation forêt	`bdtopo_ZONE_VEG_FORET`	Zone de végétation
Zone végétation vigne	`bdtopo_ZONE_VEG_VIGNE`	Zone de végétation
Zone végétation verger	`bdtopo_ZONE_VEG_VERGER`	Zone de végétation
Zone végétation lande	`bdtopo_ZONE_VEG_LANDE`	Zone de végétation
Cours d'eau	`bdtopo_COURS_EAU`	Hydrographie
Surface en eau	`bdtopo_SURFACE_EAU`	Hydrographie
Barrage	`bdtopo_BARRAGE`	Infrastructure
Éolienne	`bdtopo_EOLIENNE`	Infrastructure
Cours d'eau nommé	`nom_cours_eau`	(texte, TOPONYME)

Table 1.5 – Catégories BD TOPO et colonnes correspondantes

1.6.3 Score BD TOPO et score final

Le score BD TOPO d'un polygone est la moyenne des scores des catégories actives :

$$\text{score_bdtopo}(p) = \frac{1}{|C_p|} \sum_{c \in C_p} \text{score_classe_bdtopo}(c)$$

Le score final est une pondération 50/50 :

$$\text{score_final}(p) = \begin{cases} 0.5 \times \text{score_cosia}(p) + 0.5 \times \text{score_bdtopo}(p) & \text{si } |C_p| > 0 \\ \text{score_cosia}(p) & \text{sinon} \end{cases}$$

1.6.4 Optimisations

- **Index spatial R-Tree** construit une seule fois pour tout le GPKG COSIA
- **ZONE_DE_VEGETATION** (594 000 entités) mise en cache après filtrage bbox initial
- Opérations vectorisées NumPy pour le calcul du score final

1.6.5 Sorties

- `COSIA_SCORE_finale_ecolab.gpkg` — polygones finaux avec toutes les colonnes
- `COSIA_SCORE_finale_attrs.csv` — attributs seuls

1.7 Étape 05 — Export QGIS

Script : `05_export_qgis_v2.py`

1.7.1 Quintiles et couleurs

Le score final est discrétisé en 5 classes par quintiles (20%, 40%, 60%, 80%) :

Quintile	Couleur	Hex	Signification
Q1 (0–20%)	Vert foncé	`#1a7a2e`	Très protecteur
Q2 (20–40%)	Vert clair	`#7ec850`	Protecteur
Q3 (40–60%)	Jaune	`#f5e642`	Neutre/mixte
Q4 (60–80%)	Orange	`#f5a623`	Développement
Q5 (80–100%)	Rouge	`#d0021b`	Très développement

Table 1.6 – Quintiles et palette de couleurs

1.7.2 Fichier QML

Un fichier de style `.qml` est généré automatiquement avec les intervalles de quintiles, de sorte que QGIS charge le style dès l'ouverture du GeoPackage.

1.7.3 Grille de tuiles 1km × 1km

En plus des polygones individuels, une grille de tuiles d'1 km² est calculée avec le score moyen pondéré par surface :

$$\text{score_tuile} = \frac{\sum_i \text{score}_i \times \text{aire}_i}{\sum_i \text{aire}_i}$$

1.7.4 Sorties

- `COSIA_BD_ecolab_carte_finale.gpkg` — GeoPackage final (renommage sans copie)
- `COSIA_BD_ecolab_carte_finale.qml` — style QGIS auto-chargé
- Couche `TUILES_SCORE` ajoutée au même GeoPackage

1.8 Étape 06a — Articles par parcelle

Script : `06_articles_par_parcelle_v2.py`

1.8.1 Objectif

Associer 3 articles de presse pertinents à chaque classe COSIA et catégorie BD TOPO, via une recherche sémantique en deux temps.

1.8.2 Workflow en 2 temps

1. **Recherche par embeddings (cosine similarity)** : Pour chaque label (classe/catégorie), un article synthétique de référence est encodé, puis les 15 articles les plus proches du corpus sont récupérés.
2. **Scoring LLM** : Ollama/Mistral note chaque candidat de 0.0 à 1.0 pour sa pertinence. Les 3 meilleurs sont conservés.

1.8.3 Articles synthétiques

Pour chaque label, un article de référence de 300–500 mots est rédigé manuellement, mentionnant explicitement le contexte du SCoT Drôme-Ardèche. Ceci guide la recherche sémantique vers des articles localement pertinents.

1.8.4 Cache d'embeddings

```python
# Sauvegarde
np.save("articles_embeddings_cache.npy", embeddings_array)
pd.DataFrame({"url": urls}).to_csv("articles_embeddings_index.csv")

# Chargement (si cache existant)
if cache_exists:
    embeddings = np.load("articles_embeddings_cache.npy")
    urls = pd.read_csv("articles_embeddings_index.csv")["url"].tolist()
```

Listing 1.4 – Système de cache d'embeddings

1.8.5 Résumé COSIA par Ollama

Pour chaque classe COSIA, un résumé de 3–5 phrases est généré par Mistral à partir des 3 articles retenus. Ce résumé est stocké dans `COSIA_articles_par_classe.csv`.

1.8.6 Sorties

— `COSIA_articles_par_classe.csv` — 15 lignes (une par classe), avec 3 URLs + titres COSIA, 6 URLs + titres contexte, résumé

— `COSIA_BD_ecolab_articles.qml` — Map Tips QGIS (HTML avec liens cliquables)

1.9 Étape 06b — Résumés BD TOPO

Script : `06b_resume_bdtopo.py`

1.9.1 Objectif

Générer un résumé textuel pour chaque combinaison unique de catégories BD TOPO présente dans le GeoPackage. Par exemple, un polygone situé à la fois en forêt publique et en Natura 2000 reçoit un résumé spécifique à ce contexte.

1.9.2 Clé de combinaison

La clé est une liste triée et séparée par `|` des catégories actives :

`"FORET_PUBLIQUE|NATURA2000|ZONE_VEG_FORET"`

1.9.3 Seuil et filtrage

Seules les combinaisons comptant au moins `MIN_POLYGONS` polygones reçoivent un résumé (évite les résumés pour des combinaisons anecdotiques). Ce seuil a été baissé lors du second run pour couvrir des combinaisons rares comme `EOLIENNE|FORET_PUBLIQUE|ZONE_VEG_FORET`.

1.9.4 Sorties

— `BDTOPO_resume_par_combo.csv` — 160 lignes : `combo_key`, `n_polygones`, `resume_bdtopo`

1.10 Étape 06c — Injection des résumés dans le GPKG

Script : `06c_inject_resume_bdtopo.py`

1.10.1 Objectif

Injecter la colonne `resume_bdtopo` directement dans la table SQLite du GeoPackage pour éviter une jointure à l'exécution (plus rapide pour QGIS et l'application web).

1.10.2 Optimisations SQLite

```
conn.execute("PRAGMA journal_mode=MEMORY")  # journal en RAM
conn.execute("PRAGMA synchronous=OFF")      # pas de fsync
conn.execute("PRAGMA cache_size=100000")    # 100K pages en cache
```

Listing 1.5 – Pragmas SQLite pour writes rapides

1.10.3 Logique de mise à jour

Pour chaque combinaison unique :

```
# Construction de la clause WHERE
where_parts = []
for cat in ALL_BDTOPO_CATS:
    val = 1 if cat in active_cats else 0
    where_parts.append(f"bdtopo_{cat} = {val}")

sql = f"""
    UPDATE COSIA_SCORE_finale
    SET resume_bdtopo = ?
    WHERE {' AND '.join(where_parts)}
"""
conn.execute(sql, (resume_text,))
```

Listing 1.6 – UPDATE ciblé par combo BD TOPO

1.11 Application web interactive

Script : `app_carte2.py`

1.11.1 Architecture technique

L'application combine trois couches :

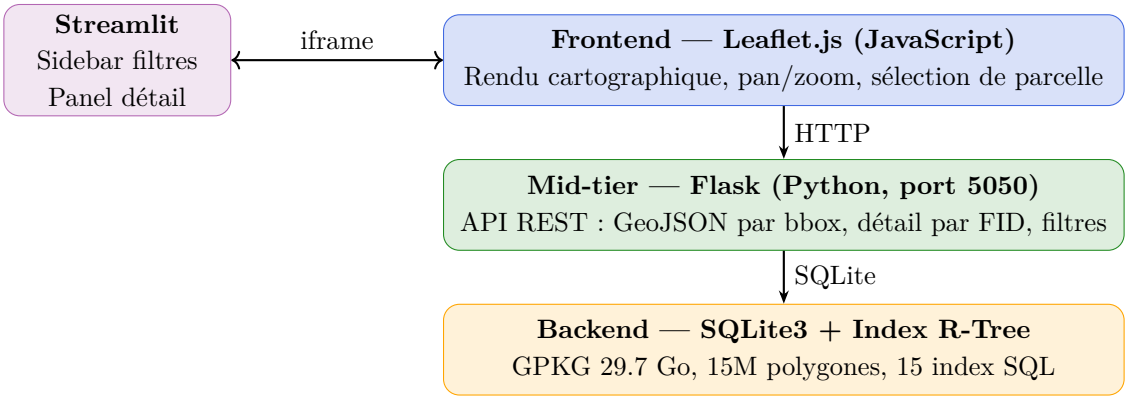

FIGURE 1.2 – Architecture de l'application web

1.11.2 Flask — Routes API

Route	Méthode	Rôle
`/api/features`	GET	GeoJSON des polygones dans la bbox courante
`/api/detail/<fid>`	GET	Tous les attributs d'un polygone (articles, scores...)
`/api/filter_bbox`	GET	Bbox de l'ensemble des résultats filtrés
`/api/select/<fid>`	GET	Stocker le FID sélectionné en session

TABLE 1.7 – Routes de l'API Flask

1.11.3 Filtre et chargement

```
conditions = ["1=1"]
params = []

# Filtre par classes COSIA
if classes_filter:
    placeholders = ",".join("?" * len(classes_filter))
    conditions.append(f"classe IN ({placeholders})")
    params.extend(classes_filter)

# Filtres BD TOPO (AND logique)
for cat in bdtopo_filter:
    conditions.append(f"bdtopo_{cat} = 1")

# Filtre bbox viewport
conditions.append("""
```

```
    (minx <= ? AND maxx >= ? AND miny <= ? AND maxy >= ?)
""")
params.extend([xmax_l93, xmin_l93, ymax_l93, ymin_l93])

sql = f"""
    SELECT fid, geom, classe, score_cosia
    FROM COSIA_SCORE_finale
    WHERE {' AND '.join(conditions)}
    LIMIT 5000
"""
```

Listing 1.7 – Requête SQL avec filtres dynamiques (api_features)

1.11.4 Système de cache des bbox

Au démarrage de l'application, un thread de fond calcule et met en cache les *bounding boxes* de chaque combinaison filtre :

```
sql = """
    SELECT classe,
           MIN(minx) as xmin, MAX(maxx) as xmax,
           MIN(miny) as ymin, MAX(maxy) as ymax
    FROM COSIA_SCORE_finale
    GROUP BY classe
"""
# Resultat sauvegarde dans bbox_cache.json
#     zoom automatique instantane au filtrage suivant
```

Listing 1.8 – Pré-calcul de la bbox par classe (background thread)

1.11.5 Sidebar Streamlit — Filtres

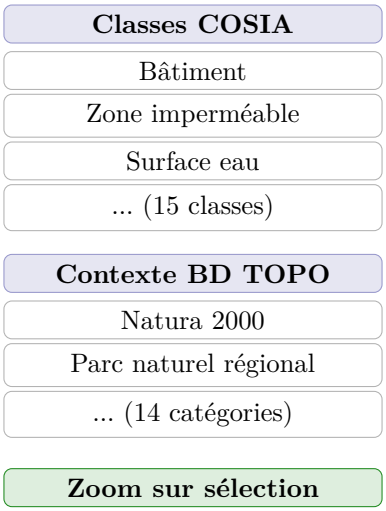

FIGURE 1.3 – Sidebar Streamlit avec filtres

1.11.6 Panel de détail parcelle

Quand l'utilisateur clique sur une parcelle sur la carte :

1. Leaflet envoie le FID à Flask (`/api/select/<fid>`)

2. Streamlit interroge `/api/detail/<fid>` (polling toutes les 2s)
3. Le panel affiche :
   — **Score global** avec jauge colorée
   — Score COSIA / Score BD TOPO séparément
   — **Badges** des catégories BD TOPO actives
   — **Articles COSIA** (3 liens cliquables) + résumé Mistral
   — **Articles contexte** (3–6 liens) pour le contexte BD TOPO
   — **Résumé BD TOPO** généré par Ollama pour la combinaison

1.11.7 Carte Leaflet

```
# Seuils quantiles du GPKG final
SCORE_THRESHOLDS = [-0.531, -0.465, -0.396, -0.297]

# Palette de couleurs
SCORE_COLORS = ["#1a7a2e", "#7ec850", "#f5e642", "#f5a623", "#d0021b"]

# Rectangle SCoT (WGS84) affiche en tirets bleus
SCOT_BOUNDS = [[44.154, 4.460], [44.730, 5.709]]
L.rectangle(SCOT_BOUNDS, {color:'#1976D2', dashArray:'8␣5', weight:2})
```

Listing 1.9 – Seuils de score et couleurs (app_carte2.py)

Threshold de zoom : les polygones individuels ne se chargent qu'à partir du zoom 13 (environ commune), pour éviter de saturer le navigateur.

1.11.8 Performances

Opération	Temps typique
Requête bbox + GeoJSON (5000 poly.)	< 200 ms
Requête détail (1 parcelle)	< 50 ms
Calcul bbox filtre (cache chaud)	< 10 ms
Calcul bbox filtre (sans cache)	$\sim$ 2–5 s
Démarrage Flask + index warmup	$\sim$ 5 s

Table 1.8 – Performances de l'application web

1.12 Index SQLite et optimisations

Script : `create_indexes.py`

1.12.1 Index créés

15 index SQLite sont créés sur la table `COSIA_SCORE_finale` pour accélérer les filtres :

```
indexes = [
    ("idx_classe",           "classe"),
    ("idx_bdtopo_NATURA2000", "bdtopo_NATURA2000"),
    ("idx_bdtopo_PARC_PNR",   "bdtopo_PARC_PNR"),
    # ... 12 autres categories bdtopo
]

for idx_name, col_name in indexes:
    conn.execute(f"""
        CREATE INDEX IF NOT EXISTS {idx_name}
        ON COSIA_SCORE_finale ({col_name})
    """)
```

Listing 1.10 – Création des index SQLite

Temps de création

Chaque index prend ∼40 minutes sur le GeoPackage de 29.7 Go (15M lignes). Au total : ∼10 heures. À n'effectuer qu'une seule fois.

1.13 Configuration centrale

Fichier : `config_v2.py`

Toute la pipeline est configurée depuis un seul fichier. Les paramètres principaux :

```
# Chemins
BASE_DIR = Path(__file__).parent
OUT_DIR  = BASE_DIR / "outputs"
GEO_DIR  = OUT_DIR / "geo"

# Ollama
OLLAMA_URL     = "http://localhost:11434/api/generate"
OLLAMA_MODEL   = "mistral"
OLLAMA_TIMEOUT = 120
SLEEP_BETWEEN  = 0.3  # secondes entre les appels

# Departements
COSIA_DEPTS = ["D007", "D026", "D084"]
BDTOPO_DEPTS = ["D007", "D026", "D084"]

# Bbox SCoT [Lambert 93]
SCOT_BBOX = (816777, 6340562, 914455, 6407100)

# Mapping topic -> classes COSIA (125+ topics)
TOPIC_COSIA_MAP = {
    3:  ["Batiment", "Zone impermeable"],
    7:  ["Feuillu", "Conifere"],
    12: ["Surface eau"],
    ...
}

# Mapping topic -> categories BD TOPO (40+ topics)
```

```
TOPIC_BDTOPO_MAP = {
    5:  ["NATURA2000"],
    9:  ["FORET_PUBLIQUE", "ZONE_VEG_FORET"],
    ...
}
```

Listing 1.11 – Extraits de config_v2.py

1.14 Lancement de la pipeline

1.14.1 Prérequis

— Python 3.10+, GDAL/GeoPandas, PyProj, Sentence-Transformers, BERTopic

— Ollama installé localement avec le modèle Mistral (`ollama pull mistral`)

— QGIS 3.40+ pour la visualisation

— Streamlit (`pip install streamlit flask`) pour l'application web

1.14.2 Ordre d'exécution

Ordre	Script	Durée approx.
0	`bertopic_train_save.py`	30–60 min
1	`01_topic_notes_ollama_v2.py`	3–8h (50K articles)
2	`02_topic_viz_v2.py`	1–2 min
3	`03_geospatial_score_cosia_v2.py`	30 min
4	`04_enrich_cosia_bdtopo_v2.py`	45–90 min
5	`05_export_qgis_v2.py`	10–20 min
6a	`06_articles_par_parcelle_v2.py`	30–60 min
6b	`06b_resume_bdtopo.py`	30–60 min
6c	`06c_inject_resume_bdtopo.py`	10–30 min
—	`create_indexes.py`	∼10h (une fois)

Table 1.9 – Ordre et durée d'exécution des scripts

1.14.3 Lancement de l'application web

```
cd pipeline_v2
streamlit run app_carte2.py
# Interface disponible sur http://localhost:8501
# API Flask sur http://localhost:5050
```

Listing 1.12 – Démarrage de l'application Streamlit

1.15 Flux de données complet

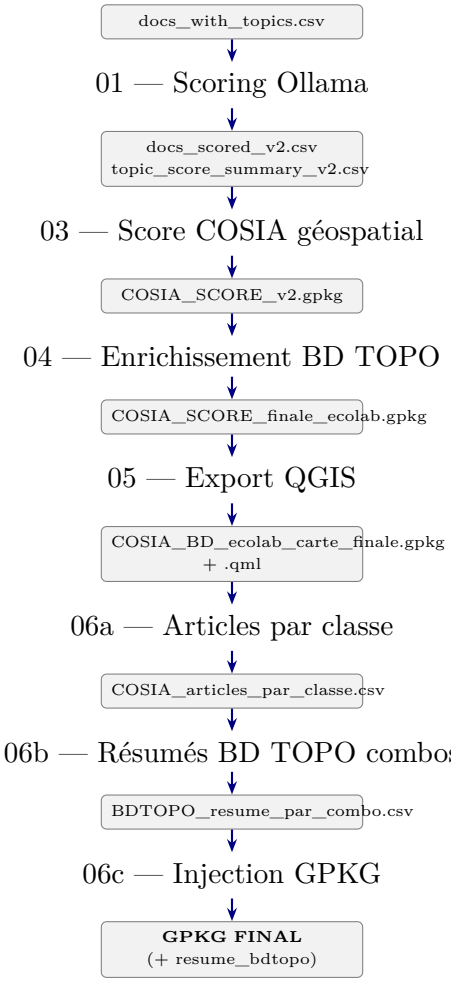

FIGURE 1.4 – Chaîne de fichiers de bout en bout

1.16 Résultats et visualisation QGIS

1.16.1 Couches disponibles dans le GPKG final

- **COSIA_SCORE_finale** (∼15M polygones) avec :
  - `classe` — classe COSIA (15 valeurs)
  - `score_cosia` — score issu des topics
  - `score_bdtopo` — score issu du contexte géographique
  - `score_polygone` — score final (blended 50/50)
  - 14 colonnes `bdtopo_*` (booléens 0/1)
  - `nom_cours_eau` — toponymie (si applicable)
  - `resume_bdtopo` — résumé Ollama de la combinaison BD TOPO
- **TUILES_SCORE** — grille 1km² avec score moyen pondéré

1.16.2 Jointure des résumés dans QGIS

Pour joindre `COSIA_articles_par_classe.csv` à la couche vecteur :

1. Propriétés de la couche → Jointures → Ajouter

2. Couche jointe : `COSIA_articles_par_classe.csv`
3. Champ de jointure de la couche : `classe`
4. Champ cible : `classe`

1.17 Choix techniques et justifications

Choix	Alternative	Justification
GeoPackage (SQLite)	PostGIS	Pas de serveur requis, portable, R-Tree intégré
Ollama local	API OpenAI	Pas de coût, données locales, reproductible
Leaflet.js	MapLibre GL	Stabilité, facilité d'intégration dans iframe
BERTopic	LDA/NMF	Meilleure cohérence des topics, support multilingue
Flask thread	FastAPI	Minimal, pas de processus externe supplémentaire
CSV pour articles	15M UPDATE	Léger, performant, jointure côté app
Bbox filter	Clip géométrique	100× plus rapide sur 15M polygones
ThreadPool I/O	ProcessPool	Évite la sérialisation GeoDataFrame, GIL ok pour I/O

Table 1.10 – Décisions d'architecture

1.18 Glossaire

COSIA Classification de l'Occupation des Sols par Imagerie Aérienne — nomenclature nationale à 15 classes pour l'occupation du sol.

BD TOPO Base de Données Topographique de l'IGN — données vectorielles de référence (forêts, cours d'eau, bâtiments...).

SCoT Schéma de Cohérence Territoriale — document de planification à l'échelle intercommunale.

BERTopic Modèle de topic modeling neuronal basé sur BERT + HDBSCAN + c-TF-IDF.

Ollama Framework local pour faire tourner des LLMs (ici Mistral) sans API payante.

HDBSCAN Hierarchical Density-Based Spatial Clustering — algorithme de clustering sans nombre de clusters fixe.

UMAP Uniform Manifold Approximation and Projection — réduction de dimension non-linéaire.

Lambert 93	Système de projection officiel français (EPSG :2154), utilisé dans le GeoPackage.
WGS84	Système géodésique mondial (EPSG :4326), utilisé dans l'application web (Leaflet).
R-Tree	Index spatial en arbre, utilisé par SQLite pour les requêtes géographiques rapides.
GeoPackage	GeoPackage — format de base de données géospatiale basé sur SQLite.
c-TF-IDF	Class TF-IDF — variante de TF-IDF calculée au niveau de chaque classe (topic) plutôt que de chaque document.

Chapitre 2

Score par ACP

2.1 Contexte et Objectifs

Ce rapport présente la démarche de construction d'un score de potentiel écologique par maille IRIS (Ilots Regroupés pour l'Information Statistique) sur le territoire du SCoT. L'objectif est de disposer d'un outil cartographique chiffré et méthodologiquement solide pour :

— Identifier les zones à fort potentiel écologique et prioriser les actions de conservation

— Orienter les inventaires naturalistes de terrain vers les secteurs les plus prometteurs

— Argumenter les zonages de protection dans le cadre de la révision du SCoT et des PLUi

— Fournir une base reproductible et opposable pour les études d'impact environnemental

Le score est construit à partir de trois sources de données officielles complémentaires, agrégées à l'échelle de l'IRIS via des intersections géométriques, puis synthétisées par une Analyse en Composantes Principales (ACP).

Source	Description	Variables extraites
CarHAB	Cartographie nationale des habitats naturels	5 indicateurs : milieux enjeu, zones humides, Shannon, nb types, pression agri
BD Forêt V2 IGN	Formations végétales forestières – 6 départements assemblés	3 indicateurs : feuillus enjeu, conifères, nb essences
COSIA	Classification IA occupation du sol (7 Go, 8,8M polygones)	4 indicateurs : végétation naturelle, artificialisation, agriculture, Shannon

2.2 Les 12 Indicateurs

Indicateur	Source	Définition	Rôle
`pct_milieu_enjeu`	CarHAB	% prairies, zones humides, milieux ouverts, autres pérennes	Positif fort
`pct_zone_humide`	CarHAB	% humidité édaphique élevée (nappe stagnante, circulante, détrempé)	Positif fort
`shannon_milieu`	CarHAB	Indice de Shannon sur les types de milieux $H = -\sum p_i \ln(p_i)$	Positif – diversité
`nb_types_milieu`	CarHAB	Nombre de types de milieux distincts par IRIS	Positif – richesse
`pct_occup_agri`	CarHAB	% occupation agricole intensive	Négatif – pression
`pct_feuillu_enjeu`	BD Forêt	% feuillus autochtones (hêtre, chênes, châtaignier, mélanges)	Positif fort
`pct_conifere`	BD Forêt	% conifères (pin sylvestre, maritime, douglas, sapin…)	Ambigu
`nb_essences`	BD Forêt	Nombre d'essences distinctes par IRIS (hors NC/NR)	Positif – diversité
`pct_veg_naturell`	COSIA	% Feuillu + Pelouse + Broussaille + Surface eau	Positif fort
`pct_artificialise`	COSIA	% Bâtiment + Zone imperméable + Serre + Piscine	Négatif fort
`pct_agri_cosia`	COSIA	% Culture + Terre labourée + Vigne	Négatif – pression
`shannon_cosia`	COSIA	Indice de Shannon sur les 15 classes COSIA	Positif – diversité

2.3 Analyse en Composantes Principales

2.3.1 Principe

Les 12 indicateurs ne sont pas indépendants – certains capturent des informations redondantes (`shannon_milieu` et `nb_types_milieu` sont très corrélés). L'ACP synthétise ces 12 dimensions en axes indépendants ordonnés par quantité d'information capturée. **Dim.1** est la direction qui différencie le mieux les IRIS entre eux, **Dim.2** la deuxième direction la plus informative, et ainsi de suite.

L'ACP est réalisée avec le package `FactoMineR` sur données standardisées (`scale.unit = TRUE`)

pour que les 12 variables de différentes unités contribuent de manière équivalente.

2.3.2 Résultat de l'ACP finale

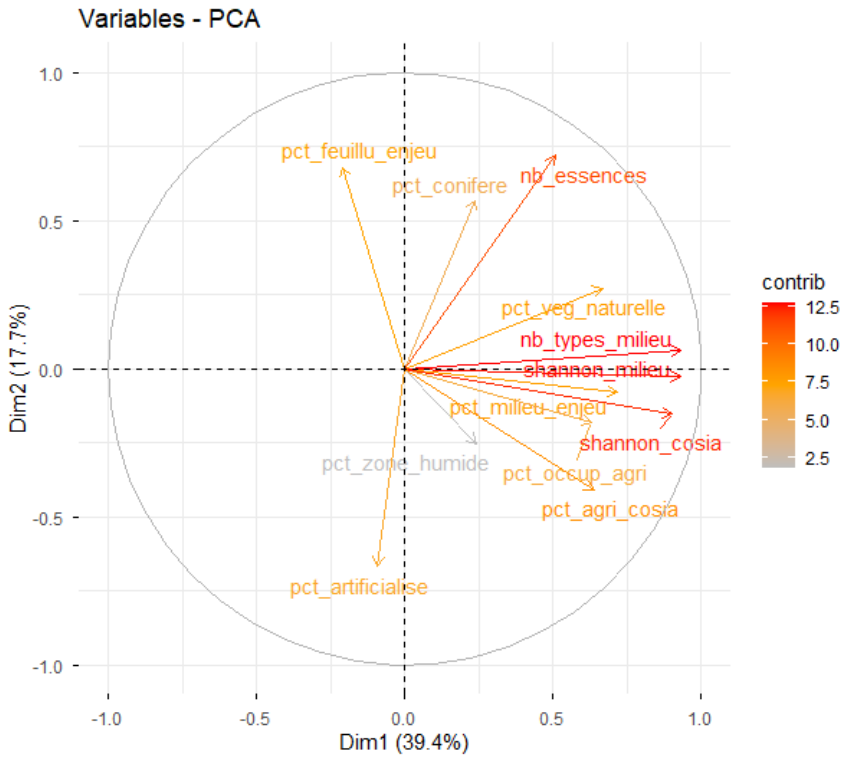

FIGURE 2.1 – Cercle des corrélations – ACP finale CarHAB + BD Forêt + COSIA

Comment lire ce cercle

Chaque flèche représente une variable. La **longueur** indique la qualité de représentation sur ces deux axes – une flèche longue (proche du bord) signifie que la variable est bien capturée par Dim.1 et Dim.2. **L'angle** entre deux flèches indique la corrélation : flèches parallèles = corrélées positivement, flèches opposées = corrélées négativement, flèches perpendiculaires = indépendantes.

> **Note :** `pct_zone_humide` présente une flèche courte car elle vit principalement sur Dim.3 (non affiché sur ce cercle). Elle contribue au score final mais est mal représentée sur ce plan Dim.1/Dim.2.

Les trois axes

Axe	Variance	Variables dominantes	Interprétation
Dim.1	39,4%	nb_types_milieu (18,4%), shannon_milieu (18,2%), shannon_cosia (17,2%)	Diversité et naturalité globale – **axe principal**
Dim.2	17,7%	nb_essences (24,4%), pct_feuillu_enjeu (21,7%), pct_artificialise (21,0%)	Qualité forestière vs artificialisation
Dim.3	∼10,0%	pct_occup_agri (29,8%), pct_zone_humide (21,2%)	Zones humides vs pression agricole
Total	**57,1%**	—	Plus de la moitié de la variance totale capturée

2.4 Construction du Score

2.4.1 Orientation des axes

Avant de combiner les axes, chaque axe est vérifié pour s'assurer que la direction positive correspond à un fort potentiel écologique :

Axe	Inversion ?	Justification
Dim.1	Non	`shannon` (+0,93), `nb_types` (+0,93), `shannon_cosia` (+0,90) tous positifs
Dim.2	Oui (signe −)	`pct_artificialise` = −0,67 : sans inversion un IRIS urbain aurait une coordonnée négative qui le pénaliserait dans le mauvais sens
Dim.3	Non	`pct_zone_humide` = +0,54 (positif), `pct_occup_agri` = −0,64 (négatif)

2.4.2 Formule du score brut

```
# Variances expliquees des 3 premiers axes
variances_final <- res_pca_final$eig[1:3, "percentage of variance"]
# => c(39.4, 17.7, 10.0)

# Coordonnees des IRIS sur les axes
coords_final <- as.data.frame(res_pca_final$ind$coord)

# Matrice : Dim.2 inversee (signe moins)
score_matrix <- cbind(
   coords_final$Dim.1,   # naturalite/diversite       -- non inverse
  -coords_final$Dim.2,   # foret vs artificialisation -- INVERSE
   coords_final$Dim.3    # zones humides vs agri      -- non inverse
)

# Produit matriciel : somme ponderee / variance cumulee
df_final$score_brut <- as.vector(
  score_matrix %*% variances_final / sum(variances_final)
)
```

Le produit matriciel calcule pour chaque IRIS :

$$\text{Score brut} = \frac{\text{Dim.1} \times 39{,}4 + (-\text{Dim.2}) \times 17{,}7 + \text{Dim.3} \times 10{,}0}{67{,}1} \tag{2.1}$$

2.4.3 Normalisation 0–100 et rôle du min/max

```
df_final$score_biodiv_final <- with(df_final,
  (score_brut - min(score_brut)) / (max(score_brut) - min(score_brut)) *
     100
)
```

$$\text{Score final} = \frac{\text{Score brut} - \min(\text{Score brut})}{\max(\text{Score brut}) - \min(\text{Score brut})} \times 100 \tag{2.2}$$

Rôle du minimum

min(Score brut) est la valeur du score brut de l'**IRIS le moins écologiquement riche** du territoire – celui qui combine le moins de milieux naturels, le plus de pression agricole et le plus d'artificialisation. En soustrayant ce minimum à tous les scores, on ramène cet IRIS à exactement 0. Tous les autres IRIS ont désormais un score positif proportionnel à leur écart avec le pire IRIS.

Rôle du maximum

max(Score brut) − min(Score brut) est l'**étendue totale** des scores bruts – la distance entre le pire et le meilleur IRIS du territoire. En divisant par cette étendue, on compresse toute la variabilité dans un intervalle $[0, 1]$, puis la multiplication par 100 donne l'échelle $[0, 100]$.

Exemple numérique

Si les scores bruts vont de $-3{,}2$ (pire IRIS, vallée du Rhône) à $+4{,}8$ (meilleur IRIS, massif naturel), l'étendue est $4{,}8 - (-3{,}2) = 8{,}0$:

IRIS	Score brut	Calcul	Score final
Pire IRIS	$-3{,}2$	$\frac{-3{,}2-(-3{,}2)}{8{,}0} \times 100 = \frac{0}{8} \times 100$	**0**
IRIS médian	$+0{,}8$	$\frac{0{,}8-(-3{,}2)}{8{,}0} \times 100 = \frac{4{,}0}{8} \times 100$	**50**
Meilleur IRIS	$+4{,}8$	$\frac{4{,}8-(-3{,}2)}{8{,}0} \times 100 = \frac{8{,}0}{8} \times 100$	**100**

Conséquence importante : le score 0 et le score 100 sont des valeurs **relatives au territoire du SCoT**. Le score 100 signifie "l'IRIS le plus riche de ce territoire" et non "biodiversité parfaite". Ce score ne peut pas être comparé directement avec un autre territoire sans recalcul complet sur la base fusionnée.

2.5 Validations du Score

2.5.1 Test de sensibilité des pondérations

Les poids utilisés (variances expliquées par l'ACP) sont justifiés mathématiquement mais ne sont pas le seul choix possible. Trois scénarios ont été testés :

Scénario	Poids Dim.1 / Dim.2 / Dim.3	Corrélation avec score ACP
ACP – retenu	39,4% / 17,7% / 10,0%	1,000 (référence)
Poids égaux	33% / 33% / 33%	0,918
Dim.1 ultra-dominante	60% / 25% / 15%	0,9998

Toutes les corrélations dépassent **0,90** – seuil admis pour la robustesse d'un score composite. Le classement des IRIS est stable quel que soit le schéma de pondération.

2.5.2 Contribution de chaque source

Comparaison	Corrélatio	Interprétation
Score CarHAB seul vs Score final	0,95	CarHAB est la source dominante
Score COSIA seul vs Score final	0,94	COSIA apporte une information quasi équivalente à CarHAB
Score BD Forêt seul vs Score final	0,09	BD Forêt déjà capturée par CarHAB et COSIA – apport qualitatif sur Dim.2
CarHAB vs COSIA	0,87	Les deux sources principales sont très cohérentes entre elles

2.6 Cartographie et Résultats

2.6.1 Distribution du score

Statistique	Valeur	Interprétation
Minimum	0	IRIS de référence le moins riche – vallée du Rhône
1er quartile	∼17	25% des IRIS ont un score inférieur à 17
Médiane	∼37	IRIS médian du territoire
Moyenne	∼35	Légèrement inférieure à la médiane – asymétrie vers le bas
3e quartile	∼49	75% des IRIS ont un score inférieur à 49
Maximum	100	IRIS de référence le plus riche – massifs naturels

Couverture : 281 IRIS, 0 donnée manquante. La couverture complète est obtenue grâce à COSIA qui couvre l'intégralité du territoire.

2.6.2 Carte du score de potentiel écologique

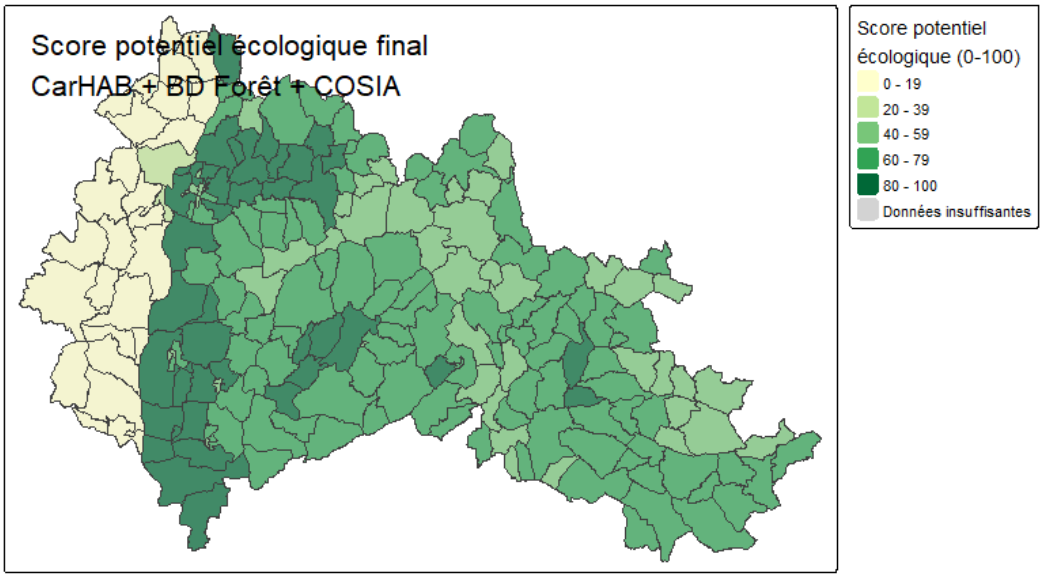

FIGURE 2.2 – Score de potentiel écologique par IRIS (0–100) – CarHAB + BD Forêt + COSIA – Mars 2026

2.6.3 Interprétation spatiale

- **Zones foncées (80–100) :** massifs naturels du centre et du sud – forte couverture en feuillus, milieux ouverts diversifiés, faible artificialisation. Quelques IRIS isolés à fort score à l'est correspondent probablement à des vallées encaissées avec zones humides et ripisylves.
- **Zones moyennes (40–60) :** espaces de transition – diversité de milieux correcte mais pression agricole modérée.
- **Zones claires (0–20) :** vallée du Rhône à l'ouest et zones périurbaines – forte artificialisation, prédominance des cultures et de la vigne.
- **Continuité spatiale :** le score varie progressivement sans ruptures artificielles, ce qui valide la cohérence méthodologique.

2.7 Limites et Perspectives

2.7.1 Limites

- **Relativité du score :** le score 100 signifie "le meilleur IRIS du territoire" et non une valeur absolue de biodiversité. Non comparable entre territoires sans recalcul.
- **Absence de connectivité :** un IRIS à fort potentiel isolé de zones naturelles voisines a une valeur écologique moindre qu'un IRIS équivalent en continuité. La connectivité n'est pas encore intégrée.

— **BD Forêt datée de 2014 :** les dynamiques forestières récentes (incendies, coupes) ne sont pas prises en compte.

— **Zones humides sous-représentées dans l'ACP :** rares sur le territoire, leur variance spatiale est faible même si leur valeur écologique est forte.

Conclusion

Le projet EcoLab apporte une réponse technique innovante et exhaustive pour l'évaluation de l'artificialisation et du potentiel écologique sur le territoire du SCOT Drôme-Ardèche. En combinant des approches méthodologiques complémentaires, ce rapport démontre la faisabilité et la pertinence d'un outil d'aide à la décision à très haute résolution :

— **Une modélisation hybride à l'échelle parcellaire :** L'intégration de l'Intelligence Artificielle (modélisation thématique BERTopic et scoring LLM via Mistral) à l'analyse spatiale (croisements avec la BD TOPO et COSIA) permet de capturer avec finesse le signal environnemental local. Ces traitements aboutissent à la création d'une cartographie web interactive performante, facilitant l'exploration des enjeux de chaque parcelle.

— **Un score statistique composite à l'échelle de l'IRIS :** Grâce à l'Analyse en Composantes Principales (ACP) exploitant les données officielles (CarHAB, BD Forêt, COSIA), 12 indicateurs ont été synthétisés pour créer un score robuste de potentiel écologique, échelonné de 0 à 100.

Ces travaux se matérialisent par des livrables concrets, notamment des bases de données optimisées (GeoPackage) et des styles automatisés pour QGIS. Ils offrent aux décideurs une base reproductible pour identifier les zones à fort potentiel, orienter les inventaires naturalistes et argumenter les zonages de protection dans le cadre des révisions du SCOT et des PLUi.

Toutefois, pour consolider et faire évoluer ce dispositif, les prochaines itérations devront prendre en compte certaines limites inhérentes aux données et aux modèles actuels. Il s'agira notamment :

— D'intégrer des métriques de connectivité écologique, essentielles pour évaluer la valeur réelle d'une zone au sein de son réseau.

— De s'appuyer sur des données forestières plus récentes pour capturer les dynamiques actuelles (incendies, coupes), la BD Forêt utilisée datant de 2014.

— De mieux pondérer la valeur des zones humides, dont l'importance écologique est majeure malgré leur sous-représentation mathématique dans l'ACP actuelle.